

Virtual Staining

Colorazione Virtuale di Immagini Istopatologiche
tramite Deep Learning

Autori: Amato Riccardo Giuseppe e Mura Andrea

Corso di Laurea: Ing. E.I.T. Curriculum Informatica

Anno accademico: 2024/2025



TABELLA DEI CONTENUTI


- Introduzione
- Pipeline generale
- Normalizzazione e maschere
- Allineamento immagini
- Creazione del dataset
- Architettura rete Pix2Pix
- Addestramento rete
- Risultati ottenuti
- Considerazioni finali

INTRODUZIONE

Le immagini istopatologiche sono fondamentali nella diagnosi medica, ma la colorazione chimica tradizionale (H&E) richiede tempo, risorse e può introdurre variabilità legata alla procedura manuale.


Le immagini label-free offrono acquisizioni più rapide e uniformi, ma non presentano i contrasti cromatici necessari per una corretta analisi istopatologica.

Questo progetto nasce con l'obiettivo di sviluppare un sistema di colorazione virtuale automatica tramite Deep Learning, in grado di simulare il processo H&E partendo da immagini label-free, garantendo così riproducibilità e riduzione del carico laboratoristico.



PIPELINE GENERALE

La pipeline implementata prevede una sequenza di step automatizzati che, a partire da immagini istopatologiche label-free e stained, consente di generare un dataset e addestrare la rete neurale per la colorazione virtuale




NORMALIZZAZIONE E MASCHERE

In questa fase viene ottimizzato il contrasto delle immagini e vengono generate maschere per isolare le aree di tessuto valide, migliorando l'individuazione dei **keypoints** per l'allineamento.

Applichiamo la normalizzazione alle immagini attraverso il metodo **CLAHE** (Contrast Limited Adaptive Histogram Equalization) che ottimizza il contrasto locale e permette una distribuzione più uniforme dei livelli di intensità. Questo intervento migliora la visibilità delle strutture rilevanti e facilita il successivo rilevamento dei **keypoints** durante la fase di allineamento.


In parallelo, generiamo una maschera binaria per individuare le sole regioni di tessuto, escludendo lo sfondo e riducendo l'influenza di eventuali artefatti. La segmentazione si basa sull'analisi dei **componenti connessi** e un **filtraggio basato sulla deviazione standard locale**, utile per discriminare regioni uniformi (sfondo) da regioni strutturate (tessuto).



ALLINEAMENTO IMMAGINI

Per confrontare correttamente le immagini, è stato necessario allinearle geometricamente.

Abbiamo confrontato due algoritmi: **SIFT** e **ORB**, capaci di rilevare punti chiave e metterli in corrispondenza.



SIFT si è rivelato l'algoritmo più affidabile in termini di precisione nel trovare corrispondenze tra le immagini, sebbene risulti più esigente dal punto di vista computazionale rispetto a ORB.




I match individuati sono stati sottoposti a un **filtraggio basato sulla distanza euclidea**, in modo da mantenere solo quelli più coerenti e significativi per la trasformazione geometrica. L'efficacia dell'allineamento è confermata visivamente dalla riduzione delle differenze locali tra le immagini, misurata tramite la differenza assoluta e analizzata negli istogrammi.

CREAZIONE DEL DATASET

Dopo l'allineamento, suddividiamo le immagini in **patch** (sottoimmagini) di dimensione **512x512** utilizzando una griglia regolare che scorre con passo costante sull'immagine. Questo approccio consente di generare un numero sufficiente di coppie label-free/stained partendo da un numero ridotto di immagini intere.

Poiché gran parte delle immagini istopatologiche includono ampie zone di sfondo, applichiamo delle maschere per selezionare automaticamente solo le regioni contenenti tessuto. In questo modo, evitiamo di includere aree non informative nel dataset e miglioriamo la qualità dell'addestramento.

Ogni coppia di patch viene poi salvata con un nome che ne riflette la posizione originale nell'immagine intera, e successivamente assegnata a uno dei tre insiemi: train, val e test, in proporzioni **70%**, **15%** e **15%**.



ARCHITETTURA PIX2PIX

Per sviluppare il progetto abbiamo scelto di usare un'architettura Pix2Pix, ovvero una rete basata su **GAN** (Generative Adversarial Network) pensata appositamente per compiti di *image-to-image translation*.

Questa tipologia di architettura è composta da due reti in competizione:

- un **generatore U-Net**, che trasforma un'immagine label-free in una versione virtualmente colorata;
- un **discriminatore PatchGAN**, che valuta la coerenza locale dell'immagine generata con quella stained originale.

Pix2Pix adotta un approccio **supervisionato** e sfrutta immagini accoppiate, offrendo un apprendimento diretto che migliora la qualità della colorazione anche in presenza di dataset contenuti. A differenza di architetture come DCGAN o StyleGAN, che generano immagini a partire da rumore casuale senza vincoli strutturali, Pix2Pix consente di apprendere trasformazioni mirate, garantendo maggiore controllo sul risultato e una coerenza visiva più elevata.

Rispetto a CycleGAN, molto diffusa in letteratura per compiti di traduzione tra domini non accoppiati, Pix2Pix offre il vantaggio di lavorare su immagini già allineate, ottenendo così risultati più fedeli alle strutture originali.

La nostra scelta è ricaduta su questa architettura proprio per esplorare un approccio più controllabile, preciso e replicabile, ideale in un contesto istopatologico dove il rigore visivo è fondamentale.

ADDESTRAMENTO RETE


Durante l'addestramento, il generatore U-Net impara a ricostruire l'immagine colorata a partire da quella label-free, attraversando una struttura **encoder-decoder** con quattro livelli di compressione e ricostruzione.

Le *skip connections* tra i blocchi simmetrici trasferiscono direttamente le feature a bassa astrazione, preservando texture e morfologie. Questo meccanismo è essenziale in ambito istopatologico, dove non basta generare immagini visivamente plausibili, ma occorre rispettare con precisione la struttura del tessuto.

La rete è ottimizzata tramite una loss combinata formata da due metriche:

- la **BCE** (Binary Cross Entropy) penalizza il generatore se il discriminatore riesce a distinguere le immagini sintetiche da quelle reali;
- la **MAE** (Mean Absolute Error), invece, minimizza la distanza assoluta tra immagine generata e target, spingendo il modello a produrre colorazioni fedeli e coerenti.




L'addestramento alterna le fasi di aggiornamento del generatore e del discriminatore, sfruttando la AMP (Automatic Mixed Precision), una tecnica introdotta da NVIDIA CUDA per eseguire parte delle operazioni in float16 al posto di float32, riducendo così memoria occupata e tempo di calcolo.



RISULTATI OTTENUTI

Il modello addestrato è stato in grado di generare immagini virtualmente colorate molto simili a quelle reali, sia dal punto di vista percettivo che visivo. Come mostrato sotto, l'output presenta una buona corrispondenza con il target, sia nella resa cromatica che nella struttura dei tessuti: i nuclei cellulari sono stati evidenziati correttamente con tonalità realistiche e le componenti locali risultano ben distinguibili, mantenendo le informazioni morfologiche presenti nell'immagine non colorata.

Durante l'addestramento, la rete ha mostrato una progressiva stabilizzazione delle perdite, e i valori ottenuti sulle immagini di validazione confermano la capacità del modello di generalizzare su dati non visti. In particolare, si è osservata un'elevata similarità strutturale tra output e target, e una ridotta differenza cromatica, segno di un apprendimento efficace.



CONSIDERAZIONI FINALI

Questo progetto rappresenta un primo passo nel tentativo di applicare tecniche di deep learning alla colorazione virtuale di immagini istopatologiche. Pur consapevoli della complessità dell'ambito medico e delle limitazioni di un lavoro accademico, siamo soddisfatti dei risultati ottenuti, che dimostrano la validità dell'approccio adottato e aprono a interessanti prospettive future.

L'obiettivo non era solo ottenere buoni risultati, ma anche costruire una pipeline chiara, replicabile e potenzialmente utile alla comunità scientifica. A tal fine, tutto il codice è stato reso disponibile in una **repository** pubblica su GitHub.

Siamo convinti che, con un set di dati più ampi e diversificati, una rete più profonda (come U-Net 3+) o l'integrazione di discriminatori più sofisticati (basati su PatchGAN++ o WGAN-GP), il modello possa migliorare ulteriormente in precisione e capacità di generalizzazione. Anche l'impiego di metriche percettive più avanzate potrà contribuire a una valutazione più completa delle performance.

Ci auguriamo che questo lavoro possa rappresentare un piccolo contributo nel campo della ricerca in ambito medico-informatico, e magari un punto di partenza per sviluppi futuri più ambiziosi.

Grazie per l'attenzione.

Amato Riccardo Giuseppe e Mura Andrea

