

Relazione Progetto Virtual Staining

Il progetto di **Virtual Staining** nasce dall'esigenza di semplificare e velocizzare il processo di analisi istopatologica attraverso tecniche di **colorazione virtuale**. In ambito medico, le immagini ottenute tramite microscopia *label-free* (generalmente in scala di grigi), pur essendo meno invasive e più rapide da acquisire, risultano di difficile interpretazione senza una colorazione specifica come quella H&E (ematossilina-eosina). L'obiettivo di questo lavoro è stato quindi quello di sviluppare un sistema in grado di trasformare automaticamente un'immagine *label-free* in una sua controparte virtualmente colorata (*stained*), riducendo i tempi di attesa e di valutazione da parte di specialisti, oltre al riuso della stessa immagine per altre tecniche di colorazione [1]. L'idea si basa sul lavoro svolto in [2], dove una rete neurale è stata addestrata per trasformare immagini di autofluorescenza in immagini istologiche realistiche.

Per raggiungere questo scopo, abbiamo progettato una pipeline che parte dall'**allineamento** tra immagini *label-free* e colorate reali, passa per la **suddivisione in sottosezioni** e culmina nell'addestramento di un modello di deep learning basato sull'architettura **Pix2Pix** [3]. Quest'ultima, composta da un **generatore** e da un **discriminatore**, è in grado di apprendere la trasformazione da un dominio all'altro attraverso un approccio supervisionato. Il risultato finale è un sistema in grado di generare immagini realisticamente colorate a partire da input privi di colorazione, con applicazioni potenzialmente molto rilevanti in ambito diagnostico [4]. Sarebbe possibile, per esempio, combinare le varie tecniche di colorazione in un'unica immagine, ottenendo così un risultato che potrebbe essere utilizzato per una diagnosi più accurata e veloce [5].

Fasi del lavoro svolto


Il progetto prevede una pipeline articolata in più fasi distinte, ciascuna delle quali è risultata fondamentale per il corretto apprendimento e la generazione delle immagini colorate. Di seguito si riportano le principali tappe operative:

1. **Allineamento delle immagini:** La prima fase ha riguardato l'allineamento spaziale tra le immagini *label-free* e le corrispondenti immagini colorate H&E. Poiché le due immagini possono presentare disallineamenti dovuti al processo di acquisizione, è stato necessario calcolare una trasformazione affine basata su feature locali ottenute attraverso l'ausilio di algoritmi come **ORB** e **SIFT**, implementati in OpenCV [6]. A tal fine, si è utilizzato l'algoritmo **SIFT** per l'estrazione dei *keypoints*, associato a un sistema di normalizzazione del contrasto (**CLAHE**), sviluppo di maschere e filtraggio euclideo, al fine di migliorare la qualità delle corrispondenze. La matrice di trasformazione risultante è stata poi applicata all'intera immagine colorata e alla relativa maschera.
2. **Suddivisione in patch:** Una volta ottenuta l'immagine allineata, si è proceduto a suddividerla in sottoregioni regolari (*patch*) di dimensione 512×512 pixel, con passo di 300 pixel. Questa suddivisione ha permesso di generare un numero consistente di coppie immagine *label free-stained* da utilizzare durante l'addestramento. Per garantire la qualità del dataset, sono stati esclusi automaticamente i quadranti contenenti prevalentemente sfondo.
3. **Creazione del dataset strutturato:** Le patch ottenute sono state organizzate in un dataset strutturato secondo la convenzione **train/val/test**, rispettando una suddivisione **70/15/15**. Durante questa fase è stata verificata la coerenza tra ciascuna immagine *label-free* e la sua corrispondente *stained*, assicurando che ogni coppia fosse completa e correttamente nominata. L'uso di un seme randomico fisso ha garantito la riproducibilità della partizione.
4. **Addestramento del modello Pix2Pix:** Per la fase di colorazione virtuale è stata adottata una rete generativa condizionata basata sull'architettura **Pix2Pix**, composta da un generatore tipo **UNet** e da un discriminatore **PatchGAN**, implementata sul framework **PyTorch** [7]. Il modello è stato addestrato in modalità supervisionata, ottimizzando una combinazione di metriche di loss **Binary Cross Entropy (BCE)** e **Mean Absolute Error (L1)**, come proposto in [3]. Durante l'addestramento è stata eseguita una validazione periodica per monitorare l'andamento delle prestazioni su dati non visti.

Risultati ottenuti

L'addestramento e la successiva fase di testing hanno permesso di ottenere immagini virtualmente colorate che, in molti casi, riproducono fedelmente le strutture e le cromie delle rispettive immagini target. La qualità visiva degli output è stata valutata principalmente attraverso un confronto diretto tra triple di immagini (*input*, *output*, *target*), rese disponibili grazie a uno script di visualizzazione automatica.

Di seguito è riportata una delle triple sopra menzionate:



Competenze acquisite

Nel corso del progetto sono state acquisite competenze tecniche rilevanti sia nell'ambito dell'elaborazione di immagini che del deep learning. In particolare, è stato approfondito l'uso di tecniche di **preprocessing** come l'equalizzazione locale del contrasto (**CLAHE**), l'allineamento tra immagini tramite feature locali (**SIFT**) e la mascheratura selettiva per l'esclusione automatica di regioni non informative.

Un'altra area centrale ha riguardato l'addestramento di reti neurali generative, dove è stato utilizzato il framework **PyTorch** per implementare e addestrare il modello **Pix2Pix** e, successivamente, una variante avanzata con **UNet** e discriminatore migliorato, simile all'approccio proposto in [8], [9]. Questo ha incluso l'impiego di tecniche come la normalizzazione delle immagini, la gestione dei batch su GPU, l'ottimizzazione di più funzioni di perdita e il salvataggio dei checkpoint per un monitoraggio efficiente dell'apprendimento.

Infine, il progetto ha richiesto una buona **organizzazione della pipeline sperimentale**, includendo il logging delle sessioni, la validazione periodica e la generazione automatica dei risultati grafici. Questo ha permesso di affinare anche capacità trasversali di debugging, documentazione e valutazione critica del comportamento dei modelli.

Considerazioni finali

L'esperienza progettuale si è rivelata estremamente formativa sia dal punto di vista tecnico che metodologico. Ha permesso di applicare concetti teorici a un problema reale e attuale, affrontando sfide pratiche legate alla qualità del dato, all'efficienza computazionale e alla progettazione di modelli generativi condizionati.

In prospettiva, questo lavoro potrebbe rappresentare un punto di partenza utile per chiunque voglia approfondire l'applicazione di tecniche di deep learning alla colorazione virtuale di immagini biomediche. La struttura modulare della pipeline e la chiarezza del codice la rendono facilmente adattabile ad altri contesti o a nuovi dataset. L'intero progetto è stato reso disponibile pubblicamente nella repository GitHub: <https://github.com/RikiXY/Virtual-Staining>, con l'obiettivo di condividerne i risultati e favorire possibili estensioni o contributi futuri da parte della comunità.

Bibliografia

- [1] L. Latonen, S. Koivukoski, U. Khan, and P. Ruusuvuori, "Virtual staining for histology by deep learning," *Trends in Biotechnology*, vol. 42, no. 9, pp. 1177–1186, 2024. doi: [10.1016/j.tibtech.2024.02.009](https://doi.org/10.1016/j.tibtech.2024.02.009)
- [2] Y. Rivenson et al., "Virtual histological staining of unlabelled tissue-autofluorescence images via deep learning," *Nature Biomedical Engineering*, vol. 3, no. 6, pp. 466–477, 2019. doi: [10.1038/s41551-019-0362-y](https://doi.org/10.1038/s41551-019-0362-y)
- [3] P. Isola, J.-Y. Zhu, T. Zhou, and A. A. Efros, "Image-to-image translation with conditional adversarial networks," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Honolulu, HI, USA, pp. 1125–1134, 2017. doi: [10.1109/CVPR.2017.632](https://doi.org/10.1109/CVPR.2017.632)
- [4] W. Lin, Y. Hu, R. Zhu, B. Wang, and L. Wang, "Virtual staining for pathology: Challenges, limitations and perspectives," *Intelligent Oncology*, vol. 1, no. 1, pp. 105–119, 2025. doi: [10.1016/j.intonc.2025.03.005](https://doi.org/10.1016/j.intonc.2025.03.005)
- [5] M. Kawai et al., "Virtual multi-staining in a single-section view for renal pathology using generative adversarial networks," *Computers in Biology and Medicine*, vol. 182, p. 109149, 2024. doi: [10.1016/j.combiomed.2024.109149](https://doi.org/10.1016/j.combiomed.2024.109149)
- [6] OpenCV Developers, "OpenCV: Open Source Computer Vision Library," [Online]. Available: <https://opencv.org>
- [7] PyTorch Developers, "PyTorch: Open source machine learning framework," [Online]. Available: <https://pytorch.org>
- [8] B. Bai et al., "Deep learning-enabled virtual histological staining of biological samples," *Light: Science & Applications*, vol. 12, no. 57, pp. 1–20, 2023. doi: [10.1038/s41377-023-01104-7](https://doi.org/10.1038/s41377-023-01104-7)
- [9] U. Khan et al., "The effect of neural network architecture on virtual H&E staining: Systematic assessment of histological feasibility," *Patterns*, vol. 4, p. 100725, 2023. doi: [10.1016/j.patter.2023.100725](https://doi.org/10.1016/j.patter.2023.100725)